

DESENVOLVIMENTO DE R SCRIPT PARA EXTRAÇÃO DE INFORMAÇÕES DO CURRÍCULO LATTES EM FORMATO XML

SANTOS, Luis Felipe Macedo, FERREIRA, Arthur de Sá Ferreira

¹Programa de Pós-graduação em Desenvolvimento Local, ²Centro Universitário Augusto Motta

Introdução

A Plataforma Lattes é a principal base de dados acadêmicos e científicos no Brasil, reunindo informações sobre formação, produção intelectual e atuação profissional de pesquisadores. Entre os registros disponíveis, destacam-se as bancas examinadoras de trabalhos de conclusão de curso, dissertações e teses, que revelam redes de colaboração e trajetórias acadêmicas relevantes. No entanto, a ausência de ferramentas especializadas dificultam a extração em larga escala e a análise sistemática dos dados.

O presente trabalho descreve o desenvolvimento de um script em R especificamente para a extração automatizada de informações sobre bancas examinadoras no Currículo Lattes, com foco na contribuição ao Observatório do Programa de Pós-graduação em Desenvolvimento Local da UNISUAM.

Metodologia

O Observatório DL está sendo desenvolvido em R Markdown, que possibilita a criação de relatórios dinâmicos, combinando programação com produção textual em um único arquivo e permitindo a exportação para formatos como PDF. Para dar suporte ao projeto, foi criada a organização do Programa no GitHub (www.github.com/PPGDL-UNISUAM), onde também se encontra o código-fonte e a hospedagem pública do Observatório DL

(www.ppgdl-unisuam.github.io/observatoriodl).

O desenvolvimento foi realizado utilizando a linguagem R, explorando a manipulação de dados estruturados em XML. O **script** foi projetado para extrair e organizar informações referentes às bancas examinadoras, incluindo tipo da banca, título do trabalho, instituição, ano de realização e membros participantes.

A implementação seguiu uma abordagem iterativa:

1. mapeamento das seções relevantes no XML;

2. criação de funções de parsing para coleta das variáveis de interesse;

3. testes com diferentes currículos para validação;

4. exportação dos dados em formato tabular, facilitando análises quantitativas e integração com outras bases.

O código encontra-se disponível em repositório público no GitHub, visando transparência e reprodutibilidade do processo.

Resultados parciais

Resultados

Os testes iniciais demonstraram que o script é capaz de processar corretamente arquivos XML de currículos Lattes e extrair, de forma estruturada, dados de bancas examinadoras. Foram obtidas tabelas contendo informações como título do trabalho avaliado, nível acadêmico (graduação, mestrado, doutorado), ano e composição da banca.

Até o momento, foram processados currículos de pesquisadores vinculados ao Programa de Pós-graduação em Desenvolvimento Local, obtendo-se registros consistentes e compatíveis com os dados disponíveis na Plataforma Lattes.

Conclusão

O script desenvolvido representa um avanço na criação de ferramentas digitais voltadas à organização e análise de informações acadêmicas no Brasil. Ao disponibilizar código aberto, contribui para a transparência e reprodutibilidade das análises, fortalecendo a gestão de dados em programas de pós-graduação.

Como próximos passos, prevê-se ampliar a base de currículos processados, integrar os módulos ao Observatório DL e expandir as análises, consolidando a plataforma como ambiente estratégico para acompanhamento das trajetórias acadêmicas e difusão do conhecimento em desenvolvimento local.