

### DESENVOLVIMENTO DE R SCRIPT PARA EXTRAÇÃO DE INFORMAÇÕES DO CURRÍCULO LATTES EM FORMATO XML

SANTOS, Luis Felipe Macedo, FERREIRA, Arthur de Sá Ferreira

<sup>1</sup>Programa de Pós-graduação em Desenvolvimento Local, <sup>2</sup>Centro Universitário Augusto Motta

#### Introdução

A Plataforma Lattes, principal base acadêmica do Brasil, possui dados valiosos sobre bancas examinadoras, mas sua extração em larga escala é difícil. Este trabalho apresenta um script em R para automatizar a coleta desses dados do Lattes, visando contribuir com o Observatório do Programa de Pós-Graduação em **Desenvolvimento Local** da UNISUAM.

#### Metodologia

O Observatório DL está sendo desenvolvido em R Markdown, que possibilita a criação de relatórios dinâmicos, combinando programação com produção textual em um único arquivo e permitindo a exportação para formatos como PDF. Para dar suporte ao projeto, foi criada a organização do Programa no GitHub ([www.github.com/PPGDL-UNISUAM](http://www.github.com/PPGDL-UNISUAM)), onde também se encontra o código-fonte e a hospedagem pública do Observatório DL. O desenvolvimento foi realizado utilizando a linguagem R, explorando a manipulação de dados estruturados em XML. O **script** foi projetado para extrair e organizar informações referentes às bancas examinadoras, incluindo tipo da banca, título do trabalho, instituição, ano de realização e membros participantes.

**A implementação seguiu uma abordagem iterativa:**

1. mapeamento das seções relevantes no XML;
2. criação de funções de parsing para coleta das variáveis de interesse;
3. testes com diferentes currículos para validação;
4. exportação dos dados em formato tabular, facilitando análises quantitativas e integração com outras bases.

O código encontra-se disponível em repositório público no GitHub, visando transparência e reprodutibilidade do processo.

Resultados parciais

#### Resultados

Os testes iniciais demonstraram que o script é capaz de processar corretamente arquivos XML de currículos Lattes e extrair, de forma estruturada, dados de bancas examinadoras. Foram obtidas tabelas contendo informações como título do

trabalho avaliado, nível acadêmico (graduação, mestrado, doutorado), ano e composição da banca.

Até o momento, foram processados currículos de pesquisadores vinculados ao Programa de Pós-graduação em Desenvolvimento Local, obtendo-se registros consistentes e compatíveis com os dados disponíveis na Plataforma Lattes.

```
# Push the attributes of the child table to the 2nd level table, each table will have the unique id of the parent table as well as the column "sequencia"
# Furthermore, each child could have its own attributes, they represent different data, so we will push to individual tables.
if (grep("DADOS-BASICOS-DA-PARTICIPACAO-EM-BANCA", child_table_name, ignore.case = FALSE)) {
  if ("TIPO" %in% names(child_table_attr)) {
    # add the table as is
    TBL_dados_basicos <- rbind(TBL_dados_basicos, c(table_id, inner_table_attr, child_table_attr))
  } else {
    # insert a column "tipo" and default value N/A.
    # Because only the NATUREZA: MESTRADO has as "tipo" column, others don't, this will re-align the data.
    fixing_child_table_attr <- append(child_table_attr, "N/A", after = 1)
    # anatomy of the target table should be: "natureza", "tipo", "titulo", "ano", "pais", "idioma", "homepage", "DOI", "titulo_ingles"
    TBL_dados_basicos <- rbind(TBL_dados_basicos, c(table_id, inner_table_attr, fixing_child_table_attr))
  }
} else if (grep("DETALHAMENTO-DA-PARTICIPACAO-EM-BANCA", child_table_name, ignore.case = FALSE)) {
  TBL_detalhamento <- rbind(TBL_detalhamento, c(table_id, inner_table_attr, child_table_attr))
} else if (child_table_name == "PARTICIPANTE-BANCA") {
  TBL_participantes <- rbind(TBL_participantes, c(table_id, inner_table_attr, child_table_attr))
} else if (child_table_name == "INFORMACOES-ADICIONAIS") {
  TBL_informacoes_adicionais <- rbind(TBL_informacoes_adicionais, c(table_id, inner_table_attr, child_table_attr))
} else if (child_table_name == "SETORES-DE-ATIVIDADE") {
  # This table has 3 attributes, sharing the same name, instead of creating 3 identical columns with different data
  # We will iterate over it and push each column to a new row.
  # This is a workaround to avoid having multiple columns with the same name.
  for (attr in child_table_attr) {
    # if the attribute is empty, we will skip it
    if (attr == "") next
    TBL_setores_atividades <- rbind(TBL_setores_atividades, c(table_id, inner_table_attr, attr))
  }
} else if (child_table_name == "PALAVRAS-CHAVE") {
  # This table also has the same issue, it has 6 attributes representing the same attribute with different data.
  # We will iterate over it and push each column to a new row.
  for (attr in child_table_attr) {
    # if the attribute is empty, we will skip it
    if (attr == "") next
    TBL_palavras_chave <- rbind(TBL_palavras_chave, c(table_id, inner_table_attr, attr))
  }
}
```

#### Conclusão

O script desenvolvido representa um avanço na criação de ferramentas digitais voltadas à organização e análise de informações acadêmicas no Brasil. Ao disponibilizar código aberto, contribui para a transparência e reprodutibilidade das análises, fortalecendo a gestão de dados em programas de pós-graduação.

Como próximos passos, prevê-se ampliar a base de currículos processados, integrar os módulos ao Observatório DL e expandir as análises, consolidando a plataforma como ambiente estratégico para acompanhamento das trajetórias acadêmicas e difusão do conhecimento em desenvolvimento local.

#### Referências

(BAVARESCO, Juliano e colab. Uso da ferramenta computacional Scriptsucupira... Revista de Gestão e Secretariado, 2015.);(CIRILO, Alex Carlos Saraiva e SANTOS, Isadora Mendes Dos e MOTA, Marcelle Pereira. AnyLattes: An Application for Continuous Assessment of Lattes Curriculum Information... Sociedade Brasileira de Computação, 2025. p. 439–448.); (MENA-CHALCO, Jesús Pascual e JUNIOR, Roberto Marcondes Cesar. scriptLattes: an open-source knowledge extraction system... Journal of the Brazilian Computer Society, 2009.)